DeCovarT × CardamomOT : résumé de la note de comparaison

Message d'accompagnement de `cardamomot_decovart_scopes.pdf`

Bastien Chassagnol

2026-11-02

Ce document est une comparaison succincte des deux approches, pour voir ce que chacune peut emprunter à l'autre.

1 Pourquoi cette note

Les échanges avec Elias et les premiers résultats de simulations ont fait évoluer deux points.

1. **Pour DeCovarT, la priorité est un estimateur robuste de la covariance, plutôt que de la matrice de précision.** Les deux restent possibles dans le modèle, puisque la précision est l'inverse de la covariance, $\boldsymbol{\Omega}_j = \boldsymbol{\Sigma}_j^{-1}$. Mais une covariance bien estimée ne demande pas de retrouver les « vraies » arêtes d'un réseau (section 2.2). Les scénarios synthétiques déjà simulés gardent leur intérêt : on simule un réseau réaliste, on l'inverse, et l'on obtient une covariance plus dense, mais plus proche des forces d'interaction biologiques qu'une matrice de Toeplitz.
2. **Dans les deux projets, l'apport principal, et la principale difficulté, est de séparer la variabilité biologique de l'erreur de mesure.** La variabilité biologique est multiplicative, d'où les lois de Poisson, log-normale ou Poisson-log-normale. Le séquençage ajoute son propre bruit (Sarkar et Stephens 2021). Un modèle Poisson-log-normal multivarié, où la profondeur de séquençage entre comme un *offset* (un terme de coefficient fixé à 1), réunit les deux couches dans un même modèle (Chiquet et al. 2021).

Toutes les affirmations mathématiques de la note, et les équations de ce message, sont vérifiées par calcul formel ou numérique dans un registre SymPy (*ledger*) ; les identifiants entre crochets (V23a, …) y renvoient. Les sources et les scripts sont sur GitHub, dans le dossier `answer-cardamomOT/` de https://github.com/bastienchassagnol/DeCovarT.

1.1 Deux objectifs généraux

1.1.1 Une théorie unificatrice : une échelle de modèles de bruit

Les méthodes de déconvolution forment un continuum. Elles partent de modèles de régression qui ne cherchent pas à quantifier les sources de variabilité, comme les moindres carrés pondérés de DWLS (Tsoucas et al. 2019) ou de MuSiC (Wang et al. 2019), et vont vers des modèles probabilistes qui séparent l'erreur de mesure de la variabilité biologique. Toutes résolvent le même problème d'erreurs sur les variables : le bulk mélange des profils purifiés latents $\boldsymbol{x}_{\cdot j,i}$, dont la référence ne fournit qu'une estimation de la moyenne,

$$\boldsymbol{y}_{\cdot i} = \sum_j p_{ji} \boldsymbol{x}_{\cdot j,i} + \boldsymbol{\epsilon}_i, \qquad \boldsymbol{x}_{\cdot j,i} = \boldsymbol{\mu}_{\cdot j} + \boldsymbol{u}_{\cdot j,i}, \qquad \hat{\boldsymbol{\mu}}_{\cdot j} = \boldsymbol{\mu}_{\cdot j} + \boldsymbol{v}_{\cdot j}, \tag{1}$$

avec trois erreurs centrées : la variabilité biologique $\boldsymbol{u}$ de l'échantillon autour de la moyenne de son type, le bruit de mesure $\boldsymbol{\epsilon}$ du bulk, et l'erreur d'estimation $\boldsymbol{v}$ d'une référence construite sur un nombre fini de cellules. En substituant la référence, toutes les méthodes ajustent $\boldsymbol{y}_{\cdot i} = \hat{\boldsymbol{\mu}}\boldsymbol{p}_{\cdot i} + \boldsymbol{e}_i$, avec $\boldsymbol{e}_i = \sum_j p_{ji}(\boldsymbol{u}_{\cdot j,i} - \boldsymbol{v}_{\cdot j}) + \boldsymbol{\epsilon}_i$. Elles diffèrent par ce qu'elles supposent de $\mathrm{Cov}(\boldsymbol{e}_i \mid \boldsymbol{p}_{\cdot i})$, ce qui les ordonne sur une échelle (tableau 1), détaillée dans la vignette de revue de DeCovarT (*05-1, a ladder of noise models*).

Tableau 1 – Échelle des modèles de bruit, du moins au plus structuré. L'erreur sur la référence $\boldsymbol{v}$ peut s'ajouter à n'importe quel échelon : RNA-Sieve, MEAD et BEDwARS la modélisent (Erdmann-Pham et al. 2021 ; Xie et al. 2026 ; Cai et al. 2024 ; Cable et al. 2022 ; Chu et al. 2022).

Échelon	$\mathrm{Cov}(\boldsymbol{e}_i \mid \boldsymbol{p}_{\cdot i})$	Exemples
1. Moindres carrés (non négatifs)	$\sigma^2\mathbf{I}_G$	Bisque (après sa transformation)
2. Moindres carrés pondérés	diagonale, poids tirés de la référence ou des résidus	MuSiC, SCDC, DWLS, deMixSC
3. GLM moyenne–variance	$\varphi V(\text{moyenne})$, diagonale	DeconV (Poisson), DeMixNB
4. Quasi-vraisemblance, gaussienne asymptotique	fonction de $\boldsymbol{p}$, diagonale ou dense	RNA-Sieve, ReDeconv, DeCovarT cellule unique
5. Moindres carrés généralisés, covariance pleine	$\sum_j p_{ji}^2 \boldsymbol{\Sigma}_j$	DeCovarT (références de populations)
6. Sandwich, équations d'estimation généralisées	covariance de travail, plus un sandwich	DECALS, MEAD
7. Modèle linéaire généralisé mixte	induite par des effets aléatoires	RCTD, BayesPrism, DeCovarT lu comme un modèle mixte

Deux familles fournissent une loi jointe pour les G gènes d'un échantillon, ce qu'exigent les échelons 5 à 7 : - Les **modèles marginaux** spécifient directement la moyenne et la dépendance entre gènes (gaussienne asymptotique, moments seuls, ou copule). - Les **modèles conditionnels** spécifient la loi sachant des effets latents, dont le partage induit la corrélation (modèles mixtes, Poisson-log-normal).

Pour une réponse gaussienne (dont la fonction de lien est l'identité), les deux familles se rejoignent : c'est exactement la position de DeCovarT, modèle marginal qui se lit aussi comme un modèle linéaire mixte. L'objectif est d'écrire cette continuité comme une théorie : chaque échelon ajoute une source de variabilité identifiable, et l'on choisit l'échelon que les données permettent d'estimer.

1.1.2 Un modèle multivarié pour l'inférence plus que pour la précision

Un modèle probabiliste réellement multivarié ne devrait guère améliorer l'estimation ponctuelle des proportions par rapport à un modèle robuste qui pondère chaque gène par sa variance résiduelle (WLS) ou, en version multivariée, par une covariance pleine (GLS). Nous attendons une erreur quadratique moyenne comparable ; c'est une hypothèse à tester, pas un résultat. Le gain est ailleurs : contrairement à une régression sans vraisemblance, ou à une vraisemblance univariée, le modèle donne la variance théorique de l'estimateur, donc des intervalles de confiance non biaisés. Le modèle cellule unique de DeCovarT s'écrit

$$\boldsymbol{y}_{\cdot i} \mid \boldsymbol{p}_{\cdot i} \sim \mathcal{N}_G\Big(c_i\,\tilde{\boldsymbol{\mu}}\boldsymbol{p}_{\cdot i},\ \phi_i \sum_j p_{ji}\boldsymbol{\Sigma}_{W,j}\Big), \qquad c_i = a_i n_i, \qquad \phi_i = a_i^2 n_i, \tag{2}$$

où a_i est l'échelle globale de l'échantillon (sa profondeur par rapport à la référence) et n_i son nombre de cellules. L'information de Fisher $I(\boldsymbol{p})$ de cette vraisemblance donne $\mathrm{Var}(\hat{\boldsymbol{p}}) \approx I(\boldsymbol{p})^{-1}$.

Ignorer les corrélations entre gènes ne biaise pas forcément le point estimé, mais rend l'intervalle trop optimiste. Exemple minimal : une proportion, deux gènes de même valeur de signature m et de corrélation intra-type ρ. Les moindres carrés ordinaires et généralisés ont alors la même variance, mais la formule naïve, qui suppose les gènes indépendants, la sous-estime [V25c] :

$$\mathrm{Var}(\hat{p}) = \frac{1+\rho}{2m^2} \qquad \text{contre} \qquad \mathrm{Var}_{\text{naïve}}(\hat{p}) = \frac{1}{2m^2}. \tag{3}$$

Avec $\rho = 0{,}5$, l'intervalle naïf est trop étroit d'un facteur $\sqrt{1{,}5} \approx 1{,}22$, et la détection d'un type rare en devient trop confiante.

Une approche de type GLM permet ensuite de quantifier le rôle des facteurs techniques (de nuisance) face aux facteurs biologiques, et de les tester. Dans équation 2, la moyenne et la variance identifient séparément la profondeur et le nombre de cellules [V25b] :

$$a_i = \frac{\phi_i}{c_i}, \qquad n_i = \frac{c_i^2}{\phi_i}. \tag{4}$$

Exemple concret, les gastruloïdes de Suppinger. Le livre de reproductibilité compare un pulse de Wnt standard à 48 h à un pulse précoce à 24 h, aux temps 48, 72 et 96 h (chapitre *Early versus standard Wnt*). La différence entre les deux bras s'explique-t-elle par une profondeur de séquençage différente (a_i), par un nombre total de cellules différent (n_i), ou par un vrai changement de composition ($\boldsymbol{p}_{\cdot i}$) ? On l'écrit comme une comparaison de modèles emboîtés. En coordonnées ILR, qui respectent le simplexe, $\boldsymbol{\rho}_i = \mathrm{ilr}(\boldsymbol{p}_{\cdot i})$, et

$$\boldsymbol{\rho}_i = \boldsymbol{\rho}_0 + \boldsymbol{\beta}\,\mathbb{1}\{i \in \text{précoce}\}, \qquad \log a_i = \alpha_0 + \alpha_1 \mathbb{1}\{i \in \text{précoce}\}, \qquad \log n_i = \nu_0 + \nu_1 \mathbb{1}\{i \in \text{précoce}\}. \tag{5}$$

L'hypothèse « technique seule » est $\boldsymbol{\beta} = 0$; le rapport de vraisemblance contre le modèle complet suit asymptotiquement un χ^2_{J-1}. Les tests de $\alpha_1 = 0$ et $\nu_1 = 0$ disent quelle part de l'écart vient de la profondeur ou du nombre de cellules. Trois réserves. Avec trois réplicats par bras et par temps, l'asymptotique est fragile, et un bootstrap paramétrique du rapport de vraisemblance est préférable. Le REML ne se transpose pas directement, car la covariance dépend de $\boldsymbol{p}$ (V7c de la note) : une version approchée reste à construire. Enfin, le bras précoce n'a pas de référence cellule unique appariée, si bien qu'un état propre à ce bras serait projeté sur les types les plus proches.

2 Les axes de comparaison

2.1 Sélection des gènes : des filtres communs, des objectifs opposés

Les deux méthodes commencent par les mêmes filtres de qualité, qui sont des conditions nécessaires mais non suffisantes : cellules dégradées (forte part de lectures mitochondriales) ou doublets écartés ; gènes mitochondriaux, de protéines ribosomiques et non codants écartés du panel ; gènes constants ou nuls dans un type cellulaire écartés (notre *presence gate*, car un tel gène rend la covariance de ce type singulière). Ensuite, DeCovarT cherche des gènes qui distinguent les types, CardamomOT des gènes qui changent d'état au cours du temps.

— **DeCovarT** classe les gènes par le rapport entre la variabilité entre types et la variabilité au sein d'un type, l'équivalent d'une ANOVA ou, pour des comptes, d'une analyse de la déviance (Lund et al. 2012). Il veut aussi une loi unimodale au sein de chaque type : la somme de milliers de cellules dans un bulk rend alors le profil approximativement gaussien (théorème central limite), ce sur quoi repose équation 2.

— **CardamomOT** veut au contraire des gènes à distribution multimodale : plusieurs « bassins » correspondent à plusieurs niveaux d'activité du promoteur, et la distribution doit évoluer dans le temps. Le code utilise une distance de Wasserstein entre temps successifs et la séparation des modes de lois binomiales négatives.
— **Un piège commun : la variance brute mélange deux sources.** L'échantillonnage Poisson du séquençage (variance égale à la moyenne) et la variation de profondeur entre cellules sont techniques ; la surdispersion d'une binomiale négative est biologique (Fang et Pachter 2025). Sans correction, un classement par variance favorise les gènes très exprimés pour une raison purement technique, d'où notre covariance « débruitée » et les résidus de Pearson d'un modèle binomial négatif.
— **Une perspective peu étudiée : un critère multivarié** (une MANOVA, sous des hypothèses fortes). Pour deux types, l'information de Fisher sur la proportion combine deux termes [V23a] :

$$I(p) = n_i\, \boldsymbol{\Delta}^\top \boldsymbol{S}(p)^{-1} \boldsymbol{\Delta} + \tfrac{1}{2} \operatorname{tr}\Big[\big\{\boldsymbol{S}(p)^{-1}(\boldsymbol{\Sigma}_{W,1} - \boldsymbol{\Sigma}_{W,2})\big\}^2\Big], \qquad \boldsymbol{S}(p) = p\boldsymbol{\Sigma}_{W,1} + (1-p)\boldsymbol{\Sigma}_{W,2}, \tag{6}$$

un écart entre moyennes $\boldsymbol{\Delta} = \boldsymbol{\mu}_1 - \boldsymbol{\mu}_2$ mesuré dans la métrique de la covariance (distance de Mahalanobis), et un terme qui récompense des covariances différentes d'un type à l'autre. Le recouvrement (*overlap*) entre les deux lois gaussiennes des types combine les deux mêmes ingrédients (annexe A.4 de la note).

2.2 Existence d'une covariance contre recouvrement d'un réseau

Combien de gènes les données peuvent-elles soutenir par type cellulaire ? Il faut distinguer deux questions.

Existence. Sans contrainte, la covariance empirique d'un type n'est inversible que s'il y a strictement plus de cellules que de gènes dans ce type :

$$C_j \geq G + 1, \tag{7}$$

le « +1 » venant de l'estimation de la moyenne. En deçà, une contrainte est nécessaire : un *shrinkage* (Ledoit–Wolf (Ledoit et Wolf 2004), ou Schäfer–Strimmer (Schäfer et Strimmer 2005)), combinaison convexe entre la covariance empirique et une cible simple, qui existe dès deux cellules ; une borne sur le nombre de conditionnement $\kappa = \lambda_{\max}/\lambda_{\min}$, qui mesure aussi la difficulté numérique ; une structure imposée (Toeplitz, facteurs latents, ou une matrice diagonale, le cas univarié) ; ou, côté précision, le *graphical lasso* (Friedman et al. 2008), qui pénalise les termes hors diagonale et existe pour toute taille d'échantillon (Carter 2025). Dans CardamomOT, ce rôle est joué par la pénalité ℓ_1 vers le réseau a priori $\boldsymbol{\theta}_0$.

Retrouver le vrai réseau est beaucoup plus exigeant. Le *degré* d'un gène est son nombre de voisins dans le graphe de la précision, et d le degré maximal, celui du plus gros *hub* :

$$\deg(g) = \big|\{h \neq g : \ \omega_{gh} \neq 0\}\big|, \qquad d = \max_g \deg(g). \tag{8}$$

Pour le graphical lasso, retrouver le support demande de l'ordre de

$$C_j \gtrsim d^2 \log G \tag{9}$$

cellules par type (Ravikumar et al. 2011 ; synthèse dans Chiquet 2015, 41), sous deux conditions invérifiables sur données réelles (Chiquet 2015, 77) :

— **l'irreprésentabilité (ou incohérence).** Soit S le support de la vraie précision (diagonale comprise), S^c son complémentaire, et $\boldsymbol{\Gamma} = \boldsymbol{\Sigma} \otimes \boldsymbol{\Sigma}$ la hessienne du log-déterminant. Il faut, pour un $\alpha \in (0, 1]$,

$$\max_{e \in S^c} \left\| \boldsymbol{\Gamma}_{eS} \, \boldsymbol{\Gamma}_{SS}^{-1} \right\|_1 \leq 1 - \alpha \, : \tag{10}$$

les paires de gènes non reliées ne doivent pas être trop corrélées aux vraies arêtes, faute de quoi le lasso confond une arête absente avec ses voisines ;

— **des valeurs propres bornées**, $0 < \lambda_{\min}(\boldsymbol{\Sigma}) \leq \lambda_{\max}(\boldsymbol{\Sigma}) < \infty$: aucune direction de variance nulle ou infinie. Notre *presence gate* en supprime une cause, un gène constant dans un type, mais pas toutes : une relation linéaire entre gènes ou un gène très faiblement exprimé rapproche aussi $\lambda_{\min}$ de zéro.

Pour fixer les idées, $G = 500$ et $d = 10$ donnent $d^2 \log G \approx 620$ cellules par type, avant les constantes.

Comparaison avec la borne empirique de CardamomOT. Sans contrainte, CardamomOT recommande de ne pas dépasser une centaine de gènes (p. 28), parce que le nombre d'interactions croît comme G^2, soit 10^4 pour $G = 100$ (p. 27). Équation 9 dit la même chose : un réseau sans contrainte peut être dense, $d = G - 1$, et il faut alors $C_j \gtrsim G^2 \log G \approx 4{,}6 \times 10^4$ cellules pour $G = 100$; un réseau creux ($d = 10$) n'en demande qu'environ 460. Cette borne vaut pour un modèle graphique non dirigé à cellules gaussiennes indépendantes ; retrouver un réseau dirigé à partir d'instantanés, dont les couplages entre temps ne sont pas observés, est plus difficile (notre remarque).

L'article de CardamomOT évalue-t-il le nombre maximal de gènes ? En partie. Les simulations (HARISSA, section 3.1, p. 11) incluent des réseaux en arbre de 5, 10, 20, 50 et 100 gènes. Sur la figure 3A (p. 15), l'AUPR dirigé de CardamomOT passe d'environ 0,97 à 5 gènes à environ 0,6 à 20 gènes, 0,33 à 50 gènes et 0,2 à 100 gènes (lecture graphique), au-dessus des méthodes concurrentes mais loin de 1. Le tableau S2 donne les temps de calcul pour 1 000 cellules. Le « plafond d'identifiabilité » est discuté qualitativement (pp. 14, 27 et 28), et l'exploration systématique de l'identifiabilité en fonction de la taille du réseau et de la richesse des données est présentée comme un travail futur (p. 27). Il n'y a donc pas d'étude du nombre maximal de gènes en fonction du nombre de cellules et du degré.

2.3 La pénalité de CardamomOT et ses alternatives

— La pénalité ℓ_1 traite de la même façon tous les écarts au réseau a priori $\boldsymbol{\theta}_0$, diagonale comprise. L'article fixe $\lambda = 0{,}05 \, N_c / \sqrt{G}$ (p. 9) ; le code (version 2.0.0) utilise un seuil universel par quantile au niveau 0,5 par gène cible. La note traduit ce seuil en taux d'erreur : environ 6 % d'arêtes fausses parmi les arêtes retenues, dans un cas idéalisé.

— **Pertes trace et log-déterminant** (Zhang et Zou 2014 ; Yuan et al. 2017). Elles supposent une matrice symétrique, donc un réseau non dirigé, et ne s'appliquent pas directement à $\boldsymbol{\theta}$.

— **Lasso de groupe ou coopératif** (Chiquet et al. 2011, 2012), l'alternative la plus prometteuse : une arête est retenue ou rejetée d'un bloc à travers plusieurs bassins ou conditions, avec un signe cohérent (un activateur reste un activateur). Une variante modulaire, qui pénaliserait davantage les arêtes entre modules qu'au sein d'un module, reste à formaliser.

2.4 Modèle d'expression contre modèle de mesure

Les deux méthodes ont d'abord ignoré le bruit de séquençage ; la nouvelle version de DeCovarT le modélise explicitement.

— Au départ, seul le **modèle d'expression** était décrit : binomiale négative issue des bouffées de transcription dans CardamomOT, moments gaussiens dans DeCovarT.

— Le **modèle de mesure** est le séquençage lui-même. Le code de CardamomOT ajoute déjà un facteur de profondeur par cellule, avec un diagnostic qui indique quand le corriger : c'est l'élément que DeCovarT a le plus intérêt à emprunter.
— Dans la nouvelle version de DeCovarT, trois facteurs techniques séparent la référence cellule unique du bulk :

1. l'**échelle globale par échantillon** a_i ; elle entre par $c_i = a_i n_i$ dans la moyenne et par $\phi_i = a_i^2 n_i$ dans la variance (équation 2). ϕ_i est une échelle de variance, non un paramètre de surdispersion ;
2. le **nombre de cellules** n_i de l'échantillon, identifié avec a_i par équation 4 ;
3. une **taille de transcriptome propre à chaque type** S_j : certains types contiennent plus d'ARN, ou en libèrent plus facilement. Ce facteur sépare fractions de cellules p_{ji} et fractions de transcrits,

$$q_{ji} = \frac{p_{ji} S_j}{\sum_\ell p_{\ell i} S_\ell}. \tag{11}$$

Seuls les rapports S_j/S_ℓ comptent. Pour que le problème reste identifiable, mieux vaut disposer de mesures extérieures et indépendantes : des *spike-ins* ou de l'ARN ambiant pour la part technique de la capture, un dosage du contenu en ARN pour la taille biologique (vignette 02-1 de DeCovarT, *What is plugged in*).

— **En perspective seulement :** un **biais propre à chaque gène** entre plateformes. Un bulk « pleine longueur » compte plus de lectures pour les gènes longs, alors que les protocoles à UMI comptent les molécules à une extrémité et éliminent les doublons de PCR (Lu et al. 2025). Ce biais est faible pour des aliquotes appariées séquencées sur la même plateforme (Guo et al. 2023), fort sinon.

2.5 La diagonale du réseau et l'autorégulation

— Dans CardamomOT, θ_{gg} est une vraie boucle d'autorégulation, dirigée. Le modèle comporte deux couches par gène, l'ARNm et la protéine, et les interactions vont des protéines vers les promoteurs : un même gène est représenté par deux nœuds.
— Dans un modèle graphique gaussien, le terme diagonal est toujours positif [V24c] :

$$\omega_{gg} = \frac{1}{\mathrm{Var}(x_g \mid \boldsymbol{x}_{-g})} = \frac{1}{\sigma_{gg}\,(1 - R_g^2)} > 0, \tag{12}$$

où R_g^2 est le carré de la corrélation multiple du gène g sur tous les autres. Il ne peut donc pas porter le signe d'une auto-activation ou d'une auto-répression. Un ω_{gg} élevé signifie que le gène est bien prédit par les autres, ou que sa variance propre est faible (dégradation rapide, peu de bruit).

Une précision presque diagonale indique-t-elle une autorégulation ? Non. Si l'estimation ne retient que des termes diagonaux et des termes hors diagonale très faibles, on peut seulement conclure que les gènes du panel sont presque conditionnellement indépendants. Cela peut venir de quatre causes, sans autorégulation :

— une absence de régulation directe entre les gènes du panel ;
— des régulateurs hors du panel, dont l'effet se répartit sur chaque gène ;
— une atténuation par le bruit de mesure Poisson, qui gonfle la diagonale de la covariance des gènes peu exprimés et efface leurs corrélations ;
— une pénalité trop forte : au-delà de la plus grande corrélation observée, le graphical lasso renvoie une précision diagonale.

Dans le cas linéaire symétrique, l'autorégulation agit même en sens inverse : l'auto-activation ς_g réduit la décroissance nette $a_g = \gamma_g - \varsigma_g$, augmente la variance et *diminue* ω_{gg} (V5d et V24a de la note). Enfin, dans un modèle stationnaire, l'auto-activation et la dégradation ne sont pas séparables, puisque seule leur différence a_g intervient. CardamomOT les sépare parce qu'il reçoit les taux de dégradation en entrée et qu'il modélise la bistabilité (deux bassins), signature non linéaire d'une auto-activation.

À quoi sert l'équation de Lyapunov. Un instantané ne montre que la loi stationnaire des cellules, pas leur dynamique. Autour d'un bassin, la dynamique linéarisée $\mathrm{d}\boldsymbol{x} = \boldsymbol{A}(\boldsymbol{x} - \boldsymbol{x}^*)\,\mathrm{d}t + \boldsymbol{B}\,\mathrm{d}\boldsymbol{W}$ a pour covariance stationnaire la solution de

$$\boldsymbol{A}\boldsymbol{\Sigma} + \boldsymbol{\Sigma}\boldsymbol{A}^\top + \boldsymbol{Q} = 0, \qquad \boldsymbol{Q} = \boldsymbol{B}\boldsymbol{B}^\top. \tag{13}$$

Les deux ingrédients jouent des rôles distincts.

— $\boldsymbol{A}$ est la **matrice de régulation**, la jacobienne de la dynamique : hors diagonale, l'effet du gène h sur le gène g ; sur la diagonale, moins la décroissance nette a_g. Elle fixe comment les fluctuations sont amorties et transmises d'un gène à l'autre.
— $\boldsymbol{Q}$ est le **bruit intrinsèque** : la variance injectée par unité de temps par les événements moléculaires aléatoires (bouffées de transcription, dégradations). Ce n'est pas la variabilité marginale de chaque gène ; celle-ci est σ_{gg}, le *résultat* du filtrage de $\boldsymbol{Q}$ par $\boldsymbol{A}$. Pour un gène seul, équation 13 donne $\sigma = q/(2a)$. Un processus naissance–mort (production k, dégradation γ) a $q = 2k$ à l'équilibre et un facteur de Fano de 1 ; des bouffées de taille géométrique de moyenne b portent ce facteur à $1 + b$ [V25a]. Le bruit intrinsèque engendre donc à lui seul la surdispersion de type binomiale négative.

L'équation fait le pont entre les deux méthodes : le $\boldsymbol{\theta}$ de CardamomOT vit dans $\boldsymbol{A}$, la covariance de DeCovarT est $\boldsymbol{\Sigma}$. Deux précisions par rapport à nos discussions :

— la covariance « débruitée » de DeCovarT correspond à $\boldsymbol{\Sigma}$, pas à $\boldsymbol{A}$; plusieurs réseaux dirigés donnent la même covariance stationnaire ;
— le bruit de mesure Poisson s'ajoute *après* la dynamique et ne se propage pas dans le réseau, alors que $\boldsymbol{Q}$, lui, se propage : à profondeur fixe s, la covariance observée vaut $s^2\boldsymbol{\Sigma} + s\,\mathrm{diag}(\boldsymbol{\mu})$. Le bruit extrinsèque (taille, cycle cellulaire), commun à tous les gènes d'une cellule, est encore autre chose : un facteur partagé, que la note traite comme le terme de rang un de la profondeur.

Dans le seul cas d'une régulation symétrique avec un bruit isotrope, $\boldsymbol{\Omega} = -\frac{2}{q}\boldsymbol{A}$: la précision est proportionnelle à la matrice de régulation (V24a de la note). Pour un **réseau dirigé acyclique** (réseau bayésien gaussien), une fois les gènes ordonnés des parents vers les enfants, la précision se factorise par une matrice triangulaire (décomposition de Cholesky modifiée, V24b). L'acyclicité interdit toute boucle d'autorégulation, qui n'apparaît qu'avec le temps, dans un réseau bayésien dynamique où un gène agit sur lui-même au pas de temps suivant.

2.6 Un axe annexe : convolution, filtre de Wiener, modèle mixte

Un bulk est une somme de profils cellulaires indépendants, donc une convolution. Si l'on garde ces profils comme variables latentes, leur meilleure reconstruction pour un échantillon, sachant ses proportions, est un filtre de Wiener. Avec des lois gaussiennes, ce filtre coïncide avec le meilleur prédicteur linéaire sans biais (BLUP) d'un modèle linéaire mixte, et avec le maximum a posteriori. C'est la lecture « modèle mixte » de DeCovarT, à l'échelon 7 de tableau 1.

3 Conclusion : les pistes d'emprunts entre les deux papiers

— **DeCovarT ← CardamomOT :** le diagnostic de la part de profondeur, à appliquer avant d'estimer les covariances (section 2.4) ; les réseaux a priori (OmniPath) comme poids de pénalité ; un contrôle de séparation en bassins au sein d'un type, qui signalerait un sous-type.
— **CardamomOT ← DeCovarT :** une covariance au sein de chaque bassin, celle qui manque quand les plus fortes corrélations sont atténuées ; une vraisemblance sur données mises de côté pour choisir la pénalité (Commenges et Jacqmin-Gadda 2015) ; une mesure d'incertitude sur $\boldsymbol{\theta}$ au-delà de la variabilité entre graines, par exemple un bootstrap des cellules au sein de chaque temps.

4 Perspectives : un mélange de réseaux bayésiens dynamiques

Une contrepartie purement statistique de CardamomOT remplacerait le modèle mécaniste par un **réseau bayésien gaussien**, dont les liens sont dirigés (section 2.5), dans sa version **dynamique**, puisque les données couvrent plusieurs temps, et en **mélange**, puisque chaque cellule relève d'un régime (type, bassin) que l'on ne connaît pas :

$$z_c \sim \mathrm{Cat}(\boldsymbol{\pi}), \qquad \boldsymbol{x}_c^{(t+1)} \mid \boldsymbol{x}_c^{(t)},\, z_c = k \sim \mathcal{N}(\boldsymbol{A}_k \boldsymbol{x}_c^{(t)},\, \boldsymbol{Q}_k). \tag{14}$$

Le temps lève la principale limite d'un graphe acyclique statique. L'arête d'un gène vers lui-même au temps suivant (arête de persistance, $g_t \to g_{t+1}$) représente l'autorégulation. Deux arêtes de sens opposés entre temps successifs, $g_t \to h_{t+1}$ et $h_t \to g_{t+1}$, représentent une boucle de rétroaction. Le graphe déroulé dans le temps reste acyclique ; seules les arêtes au sein d'un même temps doivent l'être. Le temps oriente aussi ces arêtes, ce que les données d'un seul instantané ne permettent pas. Une boucle négative symétrique peut même avoir une covariance instantanée nulle, et ne se voir que dans la covariance décalée d'un pas de temps [V26a].

Deux obstacles demeurent. D'abord, le séquençage détruit les cellules : aucune cellule n'est observée à t et à $t+1$. Les seules moyennes et covariances de deux instantanés successifs laissent $\boldsymbol{A}$ indéterminée à une rotation près [V26b] ; il faut des couplages entre temps (le transport optimal de CardamomOT, un pseudotemps, un marquage métabolique) ou des perturbations.

Ensuite, sans intervention, des graphes d'orientations différentes donnent la même loi [V26d]. Des données interventionnelles, où chaque cellule porte sa propre perturbation comme dans un Perturb-seq, distinguent ces graphes : la vraisemblance retire simplement l'équation des gènes perturbés (Rau et al. 2013).

5 Détection d'un bug technique critique de librairies scientifiques

En passant de 20 à 200 gènes dans les simulations, la simulation de lois gaussiennes multivariées par `MASS::mvrnorm()`, qui passe par une décomposition complète en valeurs et vecteurs propres (routine LAPACK `dsyevr`), s'est arrêtée sur des covariances pourtant bien conditionnées (6 échecs sur 1 004 appels avec le noyau SkylakeX). La faute vient des noyaux BLAS d'OpenBLAS 0.3.20, non de R, de MASS ni de LAPACK. DeCovarT 2.6.0 tire désormais les vecteurs gaussiens à partir du facteur de Cholesky de la covariance, et un rapport de bogue a été rédigé (fichier `NEWS.md` du dépôt DeCovarT, section 2.6.0).

Références

Cable, Dylan M., Evan Murray, Luli S. Zou, et al. 2022. « Robust Decomposition of Cell Type Mixtures in Spatial Transcriptomics ». *Nature Biotechnology* 40 (4) : 517-26. https://doi.org/10

.1038/s41587-021-00830-w.

Cai, Biao, Emma Jingfei Zhang, Hongyu Li, Chang Su, et Hongyu Zhao. 2024. « Statistical Inference of Cell-Type Proportions Estimated from Bulk Expression Data ». *Journal of the American Statistical Association* 119 (548) : 2521-32. https://doi.org/10.1080/01621459.2024.2382435.

Carter, Jack Storror. 2025. « Existence of Penalised Likelihood Estimates and Posterior Propriety of Separable Prior Distributions for Gaussian Precision Matrices ». In *arXiv.org*. Https://arxiv.org/abs/2505.20005v2.

Chiquet, Julien. 2015. « Contributions to Sparse Methods for Complex Data Analysis ». Thèse de doctorat, Université Paris-Saclay / AgroParisTech.

Chiquet, Julien, Yves Grandvalet, et Christophe Ambroise. 2011. « Inferring Multiple Graphical Structures ». *Statistics and Computing* 21 (4) : 537. https://doi.org/10.1007/s11222-010-9191-2.

Chiquet, Julien, Yves Grandvalet, et Camille Charbonnier. 2012. « Sparsity with Sign-Coherent Groups of Variables via the Cooperative-Lasso ». *The Annals of Applied Statistics* 6. https://doi.org/10.1214/11-aoas520.

Chiquet, Julien, Mahendra Mariadassou, et Stéphane Robin. 2021. « The Poisson-Lognormal Model as a Versatile Framework for the Joint Analysis of Species Abundances ». *Frontiers in Ecology and Evolution* 9. https://doi.org/10.3389/fevo.2021.588292.

Chu, Tinyi, Zhong Wang, Dana Pe'er, et Charles G. Danko. 2022. « Cell type and gene expression deconvolution with BayesPrism enables Bayesian integrative analysis across bulk and single-cell RNA sequencing in oncology ». *Nature Cancer* 3 (4) : 505-17. https://doi.org/10.1038/s43018-022-00356-3.

Commenges, Daniel, et Helene Jacqmin-Gadda. 2015. *Dynamical Biostatistical Models*. Chapman ; Hall/CRC. https://doi.org/10.1201/b19109.

Erdmann-Pham, Dan D., Jonathan Fischer, Justin Hong, et Yun S. Song. 2021. « Likelihood-Based Deconvolution of Bulk Gene Expression Data Using Single-Cell References ». *Genome Research* 31 (10) : 1794-806. https://doi.org/10.1101/gr.272344.120.

Fang, Meichen, et Lior Pachter. 2025. *Extrinsic Biological Stochasticity and Technical Noise Normalization of Single-Cell RNA Sequencing Data*. bioRxiv preprint ; bioRxiv. https://doi.org/10.1101/2025.05.11.653373.

Friedman, Jerome, Trevor Hastie, et Robert Tibshirani. 2008. « Sparse Inverse Covariance Estimation with the Graphical Lasso ». *Biostatistics (Oxford, England)* 9. https://doi.org/10.1093/biostatistics/kxm045.

Guo, Shuai, Xiaoqian Liu, Xuesen Cheng, et al. 2023. « DeMixSC : A Deconvolution Framework That Uses Single-Cell Sequencing plus a Small Benchmark Dataset for Improved Analysis of Cell-Type Ratios in Complex Tissue Samples ». *bioRxiv*, 2023.10.10.561733. https://doi.org/10.1101/2023.10.10.561733.

Ledoit, Olivier, et Michael Wolf. 2004. « A well-conditioned estimator for large-dimensional covariance matrices ». *Journal of Multivariate Analysis* 88 (2) : 365-411. https://doi.org/10.1016/s0047-259x(03)00096-4.

Lu, Songjian, Jiyuan Yang, Lei Yan, et al. 2025. « Transcriptome Size Matters for Single-Cell RNA-seq Normalization and Bulk Deconvolution ». *Nature Communications* 16 (1). https://doi.org/10.1038/s41467-025-56623-1.

Lund, Steven P., Dan Nettleton, Davis J. McCarthy, et Gordon K. Smyth. 2012. « Detecting Differential Expression in RNA-Sequence Data Using Quasi-Likelihood with Shrunken Dispersion Estimates ». *Statistical Applications in Genetics and Molecular Biology* 11 (5). https://doi.org/10.1515/1544-6115.1826.

Rau, Andrea, Florence Jaffrézic, et Grégory Nuel. 2013. « Joint estimation of causal effects from observational and intervention gene expression data ». *BMC Systems Biology* 7 (1) : 111. https://doi.org/10.1186/1752-0509-7-111.

Ravikumar, Pradeep, Martin J. Wainwright, Garvesh Raskutti, et Bin Yu. 2011. « High-dimensional covariance estimation by minimizing 1-penalized log-determinant divergence ». *Electronic Journal of Statistics* 5 (none) : 935-80. https://doi.org/10.1214/11-ejs631.

Sarkar, Abhishek, et Matthew Stephens. 2021. « Separating Measurement and Expression Models Clarifies Confusion in Single-Cell RNA Sequencing Analysis ». *Nature Genetics* 53 (6) : 770-77. https://doi.org/10.1038/s41588-021-00873-4.

Schäfer, Juliane, et Korbinian Strimmer. 2005. « A Shrinkage Approach to Large-Scale Covariance Matrix Estimation and Implications for Functional Genomics ». *Statistical Applications in Genetics and Molecular Biology* 4 : Article32. https://doi.org/10.2202/1544-6115.1175.

Tsoucas, Daphne, Rui Dong, Haide Chen, Qian Zhu, Guoji Guo, et Guo-Cheng Yuan. 2019. « Accurate Estimation of Cell-Type Composition from Gene Expression Data ». *Nature Communications* 10. https://doi.org/10.1038/s41467-019-10802-z.

Wang, Xuran, Jihwan Park, Katalin Susztak, Nancy R. Zhang, et Mingyao Li. 2019. « Bulk Tissue Cell Type Deconvolution with Multi-Subject Single-Cell Expression Reference ». *Nature Communications* 10. https://doi.org/10.1038/s41467-018-08023-x.

Xie, Dongyue, Lin Gui, et Jingshu Wang. 2026. « Statistical Inference for Cell Type Deconvolution ». *Journal of the Royal Statistical Society Series B : Statistical Methodology* 88 (4) : 1449-68. https://doi.org/10.1093/jrsssb/qkag054.

Yuan, Huili, Ruibin Xi, Chong Chen, et Minghua Deng. 2017. *Differential Network Analysis via the Lasso Penalized D-Trace Loss*. arXiv:1511.09188. arXiv. https://doi.org/10.48550/arxiv.1511.09188.

Zhang, Teng, et Hui Zou. 2014. « Sparse Precision Matrix Estimation via Lasso Penalized D-trace Loss ». *Biometrika* 101 (1) : 103-20.